

Factores Asociados al Estado Final de un proyecto de Regalías

Brenda Sofia Romero Fernandez
Gerson Camilo Robledo Guasca
Wendy Dahiana Acero Acero
Docente: Elias Buitrago Bolivar

September 2026

Propuesta de estudio de caso — Programación para Analítica de Datos
Versión corregida a partir de la retroalimentación del docente (ver notas resaltadas en el documento).

1 Identificación del caso

El proyecto se desarrolla en el ámbito de la gestión y evaluación de proyectos de investigación presentados a convocatorias de regalías. Se cuenta con información histórica que permite analizar sus características e identificar variables asociadas a los diferentes estados finales.

Table 1: Identificación del caso

Problema profesional	Analizar las variables que diferencian los estados finales de los proyectos en las convocatorias de regalías.
Pregunta principal	¿Qué variables y características de los proyectos históricos tienen mayor capacidad para diferenciar los estados finales en las convocatorias de regalías?
Usuario del resultado	Pares académicos o Jefe de la Oficina de Investigaciones (ODI-UDFJC).
Alcance	Analizar si la relación con MinCiencias presenta asociación con el estado final de los proyectos, junto con otras características disponibles en la base de datos (rol UDFJC, aliado, año, duración y valor).

2 Delimitación del problema

Actualmente, la información histórica de los proyectos presentados a las convocatorias de regalías se encuentra disponible como registro de los procesos realizados, pero su análisis sistemático es limitado. Esto dificulta identificar qué características de los proyectos se relacionan con sus diferentes estados finales. En consecuencia, existe una oportunidad para aprovechar estos datos históricos y generar información que contribuya al análisis y seguimiento de futuras convocatorias. El problema se delimita al estudio de los registros históricos disponibles y a las variables seleccionadas de la base de datos. Se busca identificar cuáles de ellas presentan diferencias o asociaciones estadísticamente significativas con el estado final, con el propósito de comprender su comportamiento histórico y aportar elementos que apoyen la toma de decisiones en la gestión de futuras convocatorias.

3 Pregunta y resultado esperado

Corrección atendida: la fila “Pregunta de decisión” respondía en realidad al “Uso del resultado”. Se redactó una pregunta de decisión propia, que además incorpora el enfoque de consultoría sobre los proyectos No seleccionados (sección 10).

Corrección atendida: el “Uso del resultado” original prometía apoyar la gestión de futuras convocatorias sin aclarar cómo, lo que sonaba a una herramienta reutilizable por la oficina. Se precisó: lo reproducible es el código (alguien con Python puede volver a correrlo), no una interfaz de autoservicio para personal no técnico — coherente con la exclusión ya declarada en la sección 13.

Table 2: Pregunta y resultado esperado

Pregunta de decisión	¿Qué variables presentan diferencias o asociaciones estadísticamente significativas con el estado final de un proyecto, y cómo se distribuyen los estados finales entre los proyectos relacionados y no relacionados con MinCiencias?
Resultado esperado	Una caracterización de los proyectos históricos mediante indicadores descriptivos (KPI), pruebas estadísticas (Chi-cuadrado y ANOVA) y visualizaciones, consolidada en una tabla que indica qué variables presentan evidencia significativa y cuáles no.
Uso del resultado	Análisis histórico puntual (indicadores, pruebas y gráficos), no una herramienta de autoservicio para la oficina. Lo reproducible es el notebook: una persona con conocimientos de Python puede volver a ejecutarlo sobre una base actualizada con la misma estructura.
Reproducibilidad	Archivo institucional de seguimiento de propuestas que administra la Oficina de Investigaciones (ODI-UDFJC), exportado desde el sistema institucional de registro de convocatorias. Uso autorizado para este trabajo de curso por tratarse de información de gestión, no de investigadores individuales (ver tratamiento de datos personales abajo).
Límite del resultado	El análisis identifica asociaciones y diferencias estadísticas dentro de la base analizada, pero no establece relaciones de causalidad ni predice el resultado de futuras convocatorias.

4 Datos requeridos

Corrección atendida: se agregó Relación con MinCiencias como variable eje explícita, se definió Rol UDFJC, se precisó la fuente (sistema y autorización) y se resolvió el tratamiento de datos personales de los investigadores (Ley 1581) mediante exclusión desde la carga, en vez de anonimización posterior.

Table 3: Datos requeridos

Fuente	Archivo institucional de seguimiento de propuestas de la Oficina de Investigaciones (ODI-UDFJC), en versión anonimizada, publicado como archivo CSV (separador ;) en el repositorio del equipo
Unidad de análisis	Cada registro representa un proyecto de investigación presentado a una convocatoria de regalías, con información sobre sus características y estado final.

Datos personales (Ley 1581)	La base utilizada está anonimizada: no contiene información que permita identificar directamente a personas. El análisis se concentra exclusivamente en características generales de los proyectos.
Formato	CSV.
Volumen	Aproximadamente 305 proyectos con estado registrado. Min-Ciencias es la entidad con mayor número de registros (214 proyectos).

Table 4: Variables utilizadas en el análisis

Variable	Tipo	Función en el análisis
ESTADO	Categórica	Variable principal de interés (6 categorías)
ENTIDAD	Categórica	Entidad convocante; origen de es_MinCiencias
es_MinCiencias	Booleana (derivada)	Variable eje: True si ENTIDAD contiene “Min-Ciencias” para diferenciar entre Minciencias y las otras entidades
ALIADO	Categórica	Aliado del proyecto
ROL_UDFJC	Categórica	Papel de la Universidad Distrital en el proyecto
AÑO	Discreta	Característica temporal
MESES	Discreta	Duración del proyecto
VALOR_PROYECTO	Continua	Valor económico (convertido de texto a número)

Table 5: Distribución de la variable ESTADO

Estado	Proyectos	%
No Avalada	181	59,34
Contrato firmado	43	14,10
Desistio	27	8,85
Seleccionada	23	7,54
Avalada	17	5,57
En tramite	14	4,59
Total	305	100,00

5 Procesamiento requerido

Table 6: Procesamiento requerido

Validar	Revisar dimensiones, nombres y tipos de las variables, valores faltantes (isnull), número de categorías (nunique) y distribución de ESTADO.
Transformar	Convertir VALOR_PROYECTO a número (eliminar \$, €, separadores, espacios y guiones; pd.to_numeric(errors='coerce')); crear es_MinCiencias; construir el DataFrame de análisis df con las ocho variables.
Calcular	Frecuencias y porcentajes por estado; distribución porcentual de estados según es_MinCiencias; mediana de MESES y de VALOR_PROYECTO por estado.

Clasificar / decidir	Se conservan las seis categorías originales de ESTADO. Según el tipo de variable se elige la prueba (Chi-cuadrado o ANOVA) y se decide con la regla $p < 0,05$.
Agregar / resumir	Tablas cruzadas de ENTIDAD, ALIADO, ROL UDFJC y es_MinCiencias frente a ESTADO; tabla consolidada de resultados estadísticos.
Comunicar	Tablas, gráficos (Seaborn/Matplotlib) y conclusiones sobre las variables que presentan o no evidencia estadística de diferenciación.

6 Prueba rápida de viabilidad

Corrección atendida: la autoevaluación del equipo ya señalaba que el alcance no cabía en las semanas restantes. Con las variables y reglas ahora acotadas (8-10 variables, 3 estados finales, técnica estadística definida en la sección 9), el alcance queda más ajustado; aun así, conviene confirmarlo con el docente antes de la entrega, como exige el lineamiento de la Actividad 5 ante cualquier reducción de alcance.

Table 7: Prueba rápida de viabilidad

Pregunta	Respuesta
¿El problema pertenece a un contexto profesional identificable?	Sí
¿Los datos son necesarios para resolverlo?	Sí
¿Existe una lógica algorítmica propia más allá de ejecutar una función de biblioteca?	Sí
¿El resultado puede explicarse a un usuario no programador?	Sí
¿El alcance puede desarrollarse dentro de las semanas restantes del curso?	Sí
¿Puede definirse una condición observable para comprobar que la solución funciona?	Sí (sección 11)

7 Ficha de interpretación computacional

Corrección atendida: se cerró el caso borde de los “estados diferentes a los tres definidos”, que ya estaba identificado pero sin tratamiento: ahora se excluyen del análisis y se reportan aparte, explícitamente.

Table 8: Ficha de interpretación computacional

Entradas	Base histórica anonimizada en CSV con información de proyectos, entidades, aliados, rol UDFJC, año, duración, valor y estado.
Procesos	Explorar, validar, transformar, construir indicadores (KPI), aplicar pruebas estadísticas y visualizar.

Reglas de negocio	• Se analizan las seis categorías de ESTADO tal como aparecen en la base (No Avalada, Contrato firmado, Desistio, Seleccionada, Avalada, En tramite), sin reagruparlas. • <code>es_MinCiencias</code> es True si ENTIDAD contiene “MinCiencias” (sin distinguir mayúsculas); si ENTIDAD está vacía, se asigna False. • Variables categóricas → Chi-cuadrado de independencia; variables numéricas → ANOVA de una vía. • Nivel de significancia $\alpha = 0,05$: si $p < 0,05$ se rechaza H_0.
Salidas	KPI descriptivos, resultados de las pruebas (estadístico, grados de libertad y p-valor), tabla consolidada y tres gráficos.
Supuestos	Los registros históricos son representativos y las categorías permiten comparar proyectos. Para ANOVA se asume normalidad aproximada y varianzas similares entre grupos.
Restricciones	Grupos de tamaño muy desigual (59,34 % en No Avalada) y variables con muchas categorías pueden limitar la interpretación.
Casos borde	Valores de VALOR PROYECTO que no se pueden convertir quedan como nulos y se omiten en la prueba (<code>dropna</code>); ENTIDAD vacía se clasifica como no MinCiencias; ALIADO tiene muchas categorías con pocos registros, lo que se reporta como limitación del resultado.

8 Representación del algoritmo

El diagrama se actualizó para reflejar el flujo real del notebook: carga del CSV, exploración, transformación de VALOR PROYECTO, creación de `es_MinCiencias`, cálculo de KPI, selección de la prueba según el tipo de variable, regla de decisión con $\alpha = 0,05$, consolidación y visualización.




Figure 1: Diagrama de flujo del algoritmo (versión 3.0)

9 Técnica estadística y criterio medible

Responde directamente a la observación central del docente: se define aquí qué técnica se usa y cuál es el criterio medible de “mayor capacidad de diferenciación”, en vez de dejarlo implícito en el diagrama.

- **Variables categóricas** (`es_MinCiencias`, `ROL`, `UDFJC`, `ALIADO`): se construye la tabla de contingencia frente a `ESTADO` y se aplica la prueba Chi-cuadrado de independencia (`scipy.stats.chi2_contingency`). H_0 : no existe asociación entre la variable y el estado final. H_1 : existe asociación.
- **Variables numéricas** (`AÑO`, `MESES`, `VALOR PROYECTO`): se aplica ANOVA de una vía (`scipy.stats.f_oneway`) usando `ESTADO` como factor de agrupación. El estadístico F compara la variación entre grupos con la variación dentro de los grupos. H_0 : las medias son iguales entre los estados. H_1 : al menos una media es diferente.

- **Criterio medible:** con $\alpha = 0,05$, una variable se considera diferenciadora del estado final cuando $p < 0,05$. El resultado se presenta en una tabla consolidada (sección 12) que separa las variables con y sin evidencia estadística.
- **Indicadores descriptivos:** porcentajes por estado y medianas por estado. Se usa la mediana del valor porque la diferencia entre media y mediana muestra proyectos con valores muy altos que afectan la media.

10 Enfoque específico: relación con MinCiencias

Además de evaluar cada variable, el equipo compara la distribución de los estados finales entre los proyectos relacionados y no relacionados con MinCiencias, por ser la entidad con mayor número de registros y la variable eje del estudio.

Table 9: Proporción de proyectos No Avalada según relación con MinCiencias

Grupo	% No Avalada
Relacionados con MinCiencias (True)	68,22
No relacionados con MinCiencias (False)	38,46

La prueba Chi-cuadrado sobre esta tabla (2 grupos $\times$ 6 estados) obtuvo $\chi^2 = 37,99$, con 5 grados de libertad y $p = 3,78 \times 10^{-7}$, por lo que existe evidencia estadísticamente significativa de asociación entre `es_MinCiencias` y `ESTADO`. También se observaron diferencias descriptivas en los estados Avalada y Desistio.

11 Escenarios de verificación

Corrección atendida: los resultados esperados de ambos escenarios ahora son concretos y verificables (valores numéricos y conteos), no descripciones genéricas como “se procesan y generan indicadores”.

Table 10: Escenarios de verificación

Escenario	Entrada o condición	Resultado esperado	Qué verifica
Escenario normal	Base completa con las seis categorías de <code>ESTADO</code> .	Los porcentajes de <code>ESTADO</code> suman 100%. La tabla <code>es_MinCiencias $\times$ ESTADO</code> es de 2×6 , por lo que la prueba debe reportar $(2 - 1)(6 - 1) = 5$ grados de libertad (obtenido: 5). Cada prueba devuelve su estadístico y p-valor.	Flujo principal de la solución.
Escenario especial o inválido	Valores de <code>VALOR PROYECTO</code> con símbolos o texto (p. ej. “\$ 1.250.000”, “-”); <code>ENTIDAD</code> vacía.	“\$ 1.250.000” se convierte en 1250000; los valores que no se pueden interpretar quedan como nulos y se excluyen del ANOVA sin detener el proceso; una <code>ENTIDAD</code> vacía produce <code>es_MinCiencias = False</code> .	Comportamiento ante datos que no encajan en el flujo principal.

12 Alcance y condición de éxito

La solución incluye la carga y exploración de la base histórica; la transformación de VALOR PROYECTO; la creación de `es_MinCiencias`; la construcción de indicadores descriptivos; la aplicación de Chi-cuadrado y ANOVA; la consolidación de resultados y su visualización.

Condición de éxito: la solución es exitosa si, para cada una de las seis variables analizadas, se aplica la prueba correspondiente frente a ESTADO, se reporta el estadístico y el p-valor, y se clasifica la variable con la regla $p < 0,05$ — verificable contra los escenarios de la sección 11. Los resultados obtenidos fueron:

Table 11: Consolidación de resultados

Variable	Prueba	Estadístico	p-valor	Interpretación
es_MinCiencias	Chi-cuadrado ($gl = 5$)	37,99	$3,78 \times 10^{-7}$	Asociación significativa
ROL UDFJC	Chi-cuadrado ($gl = 25$)	60,56	$8,75 \times 10^{-5}$	Asociación significativa
ALIADO	Chi-cuadrado ($gl = 1120$)	1164,37	0,1737	Sin evidencia significativa
AÑO	ANOVA	$F = 27,79$	$4,20 \times 10^{-23}$	Diferencia significativa
VALOR PROYECTO	ANOVA	$F = 2,82$	0,0167	Diferencia significativa
MESES	ANOVA	$F = 1,13$	0,3420	Sin evidencia significativa

Cuatro de las seis variables (`es_MinCiencias`, `ROL UDFJC`, `AÑO` y `VALOR PROYECTO`) presentaron evidencia estadística de diferencias o asociación con el estado final. Estos resultados son asociaciones dentro de la base analizada y no relaciones causales. ANOVA indica que existe diferencia entre al menos algunos estados, pero no identifica entre cuáles.

13 Exclusiones explícitas y líneas futuras

- No se desarrollan modelos predictivos ni técnicas de Machine Learning para predecir el estado futuro de los proyectos.
- No se integra la solución con sistemas externos ni se realiza actualización de datos en tiempo real.
- No se automatiza la toma de decisiones sobre selección, aprobación o rechazo de proyectos; los resultados son de apoyo al análisis.
- No se establecen relaciones de causalidad.